

Objetivo del Trabajo Práctico 02

Evaluar lo visto en clase sobre clasificación y selección de modelos, utilizando validación cruzada.

Enunciado

En el presente TP trabajaremos con el conjunto de datos de imágenes denominado **Fashion-MNIST**¹. Cada imagen del set de datos representa una prenda de ropa entre 10 tipos distintos. Se trata de un dataset que busca ser similar a otro muy famoso llamado **MNIST**². En el link ubicado a pie de página pueden acceder a una descripción más detallada del dataset. Ahí pueden ver los nombres de cada clase.

Para comenzar deben **descargar del campus de la materia** el conjunto de datos, el cual se encuentra en formato csv.

Fecha límite para la entrega: **Lunes 16 de Junio de 2025, 23:50hs**. Al igual que el TP-01, la entrega de este TP se realizará a través del campus de la materia. El día **jueves 19 de Junio, antes de las 12:30**, deben entregar el informe impreso junto con la autoevaluación.

Ejercicios

1. Realizar un **análisis exploratorio** de los datos. Entre otras cosas, deben analizar la cantidad de datos, cantidad y tipos de atributos, cantidad de clases de la variable de interés (prendas de ropa) y otras características que consideren relevantes. Además se espera que con su análisis puedan responder las siguientes preguntas:
 - a. ¿Cuáles parecen ser atributos relevantes para predecir el tipo de prenda al que corresponde la imagen? ¿Cuáles no? ¿Creen que se pueden descartar atributos?
 - b. ¿Hay prendas que son más parecidas entre sí? Por ejemplo, ¿Qué es más fácil de diferenciar: las imágenes correspondientes a la clase 2 de las de la clase 1, ó las de la clase 2 de la clase 6?
 - c. Tomar una de las clases, por ejemplo la clase 8, ¿Son todas las imágenes muy similares entre sí?
 - d. Este dataset está compuesto por imágenes, esto plantea una diferencia frente a los datos que utilizamos en las clases (por ejemplo,

¹ **Fashion-MNIST**. <https://github.com/zalando-research/fashion-mnist>

² **MNIST**. https://en.wikipedia.org/wiki/MNIST_database

el dataset de Titanic). ¿Creen que esto complica la exploración de los datos?

Importante: las respuestas correspondientes a los puntos 1.a, 1.b y 1.c deben ser justificadas en base a gráficos de distinto tipo.

Ayuda: Para ayudarles en la representación gráfica les dejamos código para orientarles.

```
#####  
# Plot imagen  
img = np.array(X.iloc[12]).reshape((28,28))  
plt.imshow(img, cmap='gray')  
plt.show()  
#####
```

2. **(Clasificación binaria)** Dada una imagen se desea responder la siguiente pregunta: **¿la imagen corresponde a la clase 0 o a la clase 8?**

- A partir del dataframe original, construir un nuevo dataframe que contenga sólo al subconjunto de imágenes correspondientes a las clases 0 y 8. Sobre este subconjunto de datos, analizar cuántas muestras se tienen y determinar si está balanceado con respecto a las dos clases a predecir (si la imagen es de la clase 0 o de la clase 8).
- Separar los datos en conjuntos de train y test.
- Ajustar un modelo de KNN sobre los datos de entrenamiento utilizando una cantidad reducida de atributos (por ejemplo, 3). Probar con distintos conjuntos de atributos seleccionados a partir del análisis exploratorio -por ejemplo, varios subconjuntos distintos de 3 atributos si se eligió ese número- y comparar los resultados obtenidos. Repetir el análisis utilizando diferentes cantidades de atributos.
Para comparar los resultados de cada modelo usar el conjunto de test generado en el punto anterior.

OBS: Utilizar métricas para problemas de clasificación como por ejemplo, exactitud.

- Comparar modelos de KNN utilizando distintos atributos y distintos valores de k (vecinos). Para el análisis de los resultados, tener en cuenta las medidas de evaluación (por ejemplo, la exactitud) y la cantidad de atributos.

Observación: en este Ejercicio 2 no estamos usando k-folding ni estamos dejando un conjunto held-out. Solamente entrenamos en train y evaluamos en test, donde train y test están fijos a lo largo de los incisos c,d.

3. (**Clasificación multiclase**) Dada una imagen se desea responder la siguiente pregunta: **¿A cuál de las 10 clases corresponde la imagen?**

- a. Separar el conjunto de datos en desarrollo (dev) y validación (held-out).

Para los incisos b y c, utilizar el conjunto de datos de desarrollo. Dejar apartado el conjunto held-out en estos incisos.

- b. Ajustar un modelo de árbol de decisión. Probar con distintas profundidades (entre 1 y 10).

- c. Realizar un experimento para comparar y seleccionar distintos árboles de decisión, con distintos hiperparámetros. Nuevamente, limitarse a usar profundidades entre 1 y 10.

Para esto, utilizar validación cruzada con k-folding. ¿Cuál fue el mejor modelo? Documentar cuál configuración de hiperparámetros es la mejor, y qué performance tiene.

- d. Entrenar el modelo elegido a partir del inciso previo, ahora en todo el conjunto de desarrollo. Utilizarlo para predecir las clases en el conjunto held-out y reportar la performance.

Observación: Al realizar la evaluación utilizar métricas de clasificación multiclase como por ejemplo la exactitud. Además pueden realizar una matriz de confusión y evaluar los distintos tipos de errores para las clases.

Grupos

Los grupos deben estar conformados por 3 (y sólo 3) integrantes. Ni más, ni menos. Deberán i) registrar la conformación del grupo en la siguiente planilla, y ii) definir quién va a ser el encargado del envío (debe ser uno y sólo uno de los integrantes del grupo):

 TP-02-Grupos

NOTA: Si mantienen la conformación del grupo tal cual la del TP-01, por favor mantengan el MISMO nombre.

Acerca de la entrega

Para la entrega deberán preparar los siguientes archivos:

1. Un archivo llamado *TP-02-nombregroupo.py* con el código principal. Este archivo puede complementarse con otros archivos .py donde figure parte del código, y que sean importados y utilizados desde el archivo principal.

Como siempre, ordenar el código de la siguiente manera:

- Al inicio, un encabezado con una descripción que contemple: el nombre del grupo, los nombres de los participantes, contenido del archivo y cualquier otro dato relevante que considere importante.
- Luego la sección de los imports.
- A continuación, la carga de datos.
- Siguiendo, las funciones propias que hayan definido.
- Y finalmente, el código que no está dentro de funciones.

El código debe estar modularizado (separando bloques con `#%%`) para permitir su ejecución por fragmentos.

Todo lo que figure en el informe debe deducirse de los resultados del código.

2. Un archivo llamado *README.txt* con los requerimientos de bibliotecas utilizadas e instrucciones de cómo ejecutar el código.
3. Un informe breve (no más de 10 carillas) en pdf llamado *TP-02-Informe-nombregroupo.pdf*. Además deben entregar una copia impresa (el jueves próximo siguiente a la entrega virtual).

Ordenar el informe de la siguiente manera:

- Breve introducción al problema donde se muestre el análisis exploratorio realizado.
- Explicación sobre los experimentos realizados, incluyendo los gráficos que consideren convenientes.
- Conclusiones, incluyendo los resultados relevantes de los modelos desarrollados.

4. La planilla de autoevaluación que se explica a continuación.

Importante: No deben entregar los archivos del dataset.



Autoevaluación

Al finalizar la entrega, y **antes de enviar el TP-02**, realizar lo siguiente:

- a. **Copiar** la siguiente planilla de autoevaluación (una sola a nivel grupal) **a una carpeta personal**:

 TP-02-Autoevaluacion

- b. Completarla
- c. Descargarla como pdf y agregarla al envío virtual y en papel.