

Trabajo práctico 02

Laboratorio de Datos

1er. Cuatrimestre 2025



DEPARTAMENTO
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA



Comisión: Turjanski

Nombre del grupo: “Grupo Labo”

Integrantes: Florencia Maria Gonzalez Rouco (80/24), Marcos Matascuso (476/24), Lucia Miramontes (13/24)



Introducción

En este segundo trabajo práctico, nos propusimos explorar y analizar el conjunto de datos Fashion-MNIST, formado por imágenes en escala de grises que representan distintas prendas de ropa. A lo largo del informe se describe el recorrido completo de su desarrollo: desde una primera etapa de análisis visual, pasando por la clasificación binaria y multiclase, hasta la evaluación de modelos predictivos. La idea fue hacer foco en cómo distintas estrategias de selección de atributos y configuración de modelos influyen en su desempeño.

Primero se realizó una exploración visual del dataset para asociar cada etiqueta numérica con una prenda específica. Luego, se entrenaron modelos de clasificación binaria utilizando el algoritmo *KNN*, observando cómo la elección de atributos impacta directamente en la precisión del modelo. En una segunda etapa, se abordó el problema multiclase aplicando árboles de decisión y técnicas de validación cruzada para optimizar los hiperparámetros. Los resultados mostraron que, con una buena preparación de datos y una selección adecuada de variables, es posible alcanzar niveles de exactitud considerablemente altos incluso con modelos relativamente simples.


Análisis Exploratorio de Datos

El conjunto de datos analizado corresponde a Fashion-MNIST, una base de imágenes de prendas de ropa en escala de grises. Cada imagen está representada por 784 píxeles, que se pueden describir en una matriz de 28x28, y una columna adicional denominada "label", que indica la clase a la que pertenece cada prenda. En total, el Data Frame obtenido a partir del archivo csv contiene 70.000 filas distribuidas en 10 clases diferentes. Es decir, contiene 70.000 imágenes de prendas diferentes, clasificadas del 0 al 9 según su tipo.

Esto hace que la información no sea inmediatamente interpretable a simple vista, y obliga a realizar visualizaciones gráficas para comprender el contenido de cada observación. Por lo tanto, se podría considerar que la exploración del dataset presenta una mayor complejidad inicial y no permite detectar patrones directamente.

Como primer paso, se analizaron la estructura, dimensiones y tipos de datos del conjunto. Durante el proceso se observó que las clases están distribuidas de manera equitativa teniendo 7.000 imágenes cada una lo que se intuye es beneficioso a la hora de entrenar modelos de predicción ya que la información está balanceada.

Para poder identificar qué categoría de ropa es representada por cada etiqueta, en un principio se necesita hacer uso de todas las columnas, ya que a partir de ellas se pueden visualizar distintas imágenes. Particularmente se generaron 10 imágenes, una por clase:




Cada imagen representa un modelo cualquiera de cada clase.

Si bien fue posible identificar rápidamente algunas clases a partir de las primeras imágenes visualizadas (por ejemplo, la clase 0 como “remera”, la clase 1 como “pantalón”, la clase 3 como “vestido”, la clase 4 como “campera”, la clase 5 como “sandalia” y la clase 7 como “zapatilla”), otras categorías requirieron un análisis más detallado, observando múltiples filas, para poder determinar con mayor certeza el tipo de prenda representada. Por ejemplo:



Ambas tiras de imágenes son muestras aleatorias de filas correspondientes a las clases 8 y 9, respectivamente.

Una vez hecho esto, se observó que las imágenes de cada clase son, en su mayoría, muy parecidas entre sí y se logró asociar la clase 8 con “cartera” y la clase 9 con “bota”. Se puede apreciar que hay categorías que son más parecidas entre sí como la clase 2 y la clase 6. Por lo tanto, se hizo una comparación directa entre ambas:



Ambas tiras de imágenes son muestras aleatorias de filas correspondientes a las clases 2 y 6, respectivamente.

Ahora si, se clasifica a la etiqueta número 2 con “suéter” y a la etiqueta número 6 con “camisa”. Esto fue clave para interpretar correctamente los datos y facilitar los análisis posteriores.

Con esta información, una vez conectado el *label* con el tipo de prenda, si quisiéramos saber a qué categoría pertenece alguna fila del Data Frame alcanzaría con mirar la última columna.

Clasificación binaria

Esta parte del trabajo aborda el problema de clasificación binaria. En particular, la idea fue entrenar un modelo que permita distinguir entre dos categorías (aquellas imágenes que pertenecen a la clase 8, y aquellas que pertenecen a la clase 0).

Para ello, se construyó un subconjunto del dataset original que incluía únicamente las imagen correspondientes a esas dos clases previamente mencionadas y se analizó la cantidad de valores de cada una. Al construir este subconjunto, se verificó que existen exactamente 7000 imágenes por cada clase, lo que garantiza que el problema no presenta desbalance. La igualdad en la cantidad de muestras para ambas categorías facilita también la interpretación de métricas de evaluación, como la exactitud y la matriz de confusión.

Una vez definido el subconjunto, se separaron los datos en conjuntos de *train* (entrenamiento) y *test* (prueba). Para ello, se separaron las etiquetas (columna 'label') de las variables predictoras (los píxeles) y se realizó una partición del 80% para entrenamiento y 20% para prueba, utilizando una única división fija sin validación cruzada ni conjunto “*held-out*”.

El conjunto de entrenamiento fue utilizado para ajustar distintos modelos de vecinos más cercanos (*KNN*), probando con distintos *k* vecinos más cercanos. Para cada modelo se probó con 5, 10, 20, 30 y 50 para elegir el mejor modelo mientras que el conjunto de prueba se mantuvo apartado para evaluar la performance real de los modelos entrenados. La evaluación se realizó utilizando la métrica de exactitud, así como la matriz de confusión, que brinda información más detallada sobre los aciertos y errores del modelo en cada clase.




Con el objetivo de explorar cómo influye la cantidad y selección de atributos en el desempeño del modelo, se realizaron diversos experimentos utilizando subconjuntos reducidos de píxeles. Para la selección de éstos se calculó la imagen promedio de cada clase y luego se evaluó la diferencia absoluta entre las intensidades promedio de cada píxel. Se realizaron diversas pruebas con diferentes conjuntos de tres píxeles. Algunas combinaciones incluían aquellos que presentaban las mayores diferencias promedio entre clases, mientras que otras incluían píxeles cuya información era escasa o poco diferenciadora, con el fin de observar el impacto que tienen en la performance del modelo.

En una primera serie de experimentos, se trabajó con grupos de tres atributos (píxeles). Para seleccionar estos atributos, se calculó la suma total de los valores de cada píxel en cada clase por separado, y luego se tomó la diferencia absoluta entre ambas sumas. Esta diferencia representa cuán distinto es el valor promedio de un píxel entre las clases: cuanto mayor sea la diferencia, mayor será la capacidad discriminativa de ese píxel. A partir de este criterio se identificaron los píxeles más relevantes y se construyeron los primeros modelos *KNN*, evaluando su desempeño sobre el conjunto de prueba.

Nuestro primer modelo utilizó los píxeles 554, 526 y 538, los 3 con mayor diferencia promedio entre clases. Con ellos, se alcanzó una exactitud máxima de aproximadamente al 91,46% con el *accuracy score*. para $k = 20$, con un desempeño relativamente estable para otros valores de k . Por otro lado, una segunda prueba empleó los píxeles 39, 610 y 369, que si bien presentan alta diferencia promedio, estaban ubicadas en regiones dispersas de la imagen. Este modelo logró un 93% de exactitud para $k = 50$. Por último, se entrenó también un modelo utilizando tres píxeles con baja diferencia promedio (por ejemplo, 0, 1 y 27), obteniendo una exactitud del que no supera del 51%, lo que demuestra que una mala elección de atributos puede llevar a un rendimiento casi aleatorio.

Como era de esperarse, los modelos que utilizaron atributos informativos obtuvieron mejores resultados, mientras que aquellos contruidos con atributos poco relevantes mostraron un rendimiento significativamente inferior. Esto demuestra la importancia de una buena selección de variables en modelos simples como el *KNN*.

Como segunda selección de atributos, se calculó el promedio de ambas clases y se graficó el resultado. De esta manera se obtuvo el “modelo” de cada clase el cual fue de gran utilidad para la selección de atributos. Luego, se seleccionaron 3 píxeles a ojo en los cuales en una clase predominara el color negro casi siempre, y en la otra casi siempre tenga color claro. Con esta metodología se seleccionaron los píxeles 565, 98 y 120 y se obtuvo un *accuracy score* de 95% aproximadamente.




Imágenes promedio de las clases 0 (remera) y 8 (cartera) del conjunto Fashion-MNIST. Se destacan en rojo tres píxeles (posiciones 565, 98 y 120) elegidos por su marcada diferencia de intensidad entre ambas clases, lo que sugiere su relevancia para la clasificación.

Con estos píxeles se implementó el modelo y con 50 vecinos se obtiene una exactitud del 95,25%, lo cual termina siendo el mejor modelo tomando solo 3 atributos.

Para visualizar mejor el rendimiento del modelo, se creó una matriz de confusión que representa los aciertos y errores del clasificador. En esta matriz queda claro que los valores más altos (o los más oscuros visualmente) se encuentran en la diagonal principal, lo que indica una alta proporción de predicciones correctas para ambas clases. Por otro lado, los valores fuera de la diagonal son extremadamente bajos (de color muy claro, casi blancos), lo que evidencia que el modelo comete muy pocos errores de clasificación.

Esta distribución, al ser tan contrastante apenas se la observa, confirma de manera clara que el accuracy score es altísimo y que el modelo tiene un excelente poder discriminativo utilizando únicamente estos tres atributos seleccionados.



Esta imagen representa la matriz de confusión del mejor modelo obtenido utilizando 3 atributos seleccionados manualmente y 50 vecinos.



Posteriormente, se repitió la experiencia aumentando la cantidad de atributos utilizados. Se construyeron nuevos modelos con los 10 y luego con los 100 píxeles más relevantes (con la estrategia de la diferencia de la suma de las clases), lo que permitió analizar cómo la inclusión de más información afecta el rendimiento. Al utilizar 10 atributos, la exactitud máxima fue de 92% para $k = 35$. Además, para valores de k entre 5 y 50 la exactitud se mantuvo estable, en torno al 91/92%, mostrando una cierta consistencia del modelo frente a variaciones moderadas en el valor de k . El mejor desempeño se observó al utilizar 100 atributos y $k = 5$, se alcanzó una exactitud del 98%. Este modelo, que combinó una cantidad relativamente grande de atributos relevantes con una elección adecuada de hiperparámetro, fue el de mejor rendimiento dentro de todos los experimentos realizados. La matriz de confusión correspondiente mostró errores equilibrados entre las dos clases, con sólo 64 errores sobre un total de 2800 observaciones, lo que ratifica el buen desempeño del clasificador.

En conclusión, el análisis permitió observar que el algoritmo *KNN* puede ofrecer buenos resultados en tareas de clasificación binaria sobre imágenes, siempre que se realice una selección cuidadosa de atributos, reafirmando la importancia del análisis exploratorio y de la selección de características. El uso de métricas simples como la exactitud y la matriz de confusión fue suficiente para evaluar los modelos, gracias al balance natural del dataset.

Se comprobó además que es posible alcanzar altos niveles de precisión utilizando solo una fracción del total de píxeles, siempre que se elijan atributos relevantes y se combine con un valor adecuado del parámetro k . En contraste, el uso de variables poco informativas redujo el rendimiento del modelo a niveles cercanos al azar. Estos resultados ponen en evidencia la fuerte influencia que tiene la calidad de los atributos seleccionados y la correcta elección de hiperparámetros sobre el desempeño final del clasificador.

Un resultado interesante fue que el modelo que mejor performance obtuvo usando solo tres atributos fue aquel en el que seleccionamos a simple vista tres píxeles que mostraban una clara diferencia entre las imágenes promedio de las dos clases. Esta selección se hizo de forma visual, identificando regiones donde una clase era consistentemente más oscura o más clara que la otra. A pesar de no basarse en un cálculo estadístico preciso, este método resultó muy efectivo y superó a otros modelos construidos con criterios más sistemáticos. Esto sugiere que, en algunos casos, una observación cuidadosa y un criterio intuitivo pueden ser herramientas útiles para guiar la selección de variables. Una posible explicación es que los píxeles elegidos visualmente capturan zonas que definen el patrón principal del objeto, lo que hace que tengan un poder discriminativo muy alto. En otras palabras, aunque no sea un método formal, mirar las imágenes promedio permite identificar regiones donde se concentra gran parte de la diferencia entre clases.

Clasificación multiclase

En esta sección se aborda un problema de clasificación multiclase sobre el conjunto completo del dataset, intentando predecir a qué clase (de las 10 posibles) pertenece cada imagen. Para ello, se trabajó con modelos de árboles de decisión, realizando distintos experimentos de ajuste y selección de hiperparámetros.



Para comenzar, se realizó una partición del conjunto en dos: uno destinado al desarrollo (“dev”) para ajustar y entrenar los modelos, y otro a la evaluación final del modelo (“eval”) para poder hacerla con datos no utilizados durante el entrenamiento. Se separaron aproximadamente el 90% y el 10% para cada parte respectivamente.

Una vez definida la partición, se entrenaron distintos modelos de árbol de decisión variando su profundidad máxima con los valores 1, 3, 5 y 10, utilizando como criterio de partición la *entropía*, dado que muestra un desempeño levemente superior al índice de *gini* en este contexto. Cada modelo fue ajustado sobre el conjunto de desarrollo y evaluado en ese mismo conjunto, con el objetivo de analizar cómo afecta la profundidad del árbol a la capacidad de clasificación.

Los resultados obtenidos permitieron observar una mejora en la exactitud a medida que se incrementa la profundidad del árbol. En los modelos con profundidad muy baja, como 1 o 3, no lograron capturar la complejidad necesaria para diferenciar correctamente entre las distintas clases del conjunto. Estas configuraciones generan árboles con una estructura demasiado simple, incapaces de representar adecuadamente la variabilidad presente de los datos. En cambio, a partir de una profundidad de 5, el modelo comienza a mostrar un desempeño significativamente mejor, superando el 70% de exactitud. Con profundidad 10 se obtuvo el mejor rendimiento dentro de esta etapa, lo cual era esperable dado que el modelo gana mayor flexibilidad para ajustar los datos. Sin embargo, al evaluar estos modelos directamente sobre el mismo conjunto de entrenamiento, no se puede descartar la posibilidad de sobreajuste.


Posteriormente, se realizó un experimento de búsqueda más exhaustiva de hiperparámetros para definir la mejor combinación, empleando validación cruzada (*cross-validation*) con 5 particiones (*5-fold*). Se probaron distintas combinaciones de parámetros, incluyendo la profundidad máxima del árbol (*max_depth*), la cantidad mínima de muestras necesarias para dividir un nodo (*min_samples_split*), la cantidad mínima de muestras en hojas (*min_samples_leaf*) y el número de atributos considerados al realizar divisiones (*max_features*). Las profundidades consideradas fueron 5 y 10, mientras que para el resto de los parámetros se exploraron varios valores, permitiendo evaluar un conjunto amplio de posibles configuraciones. Para el *min_samples_split* se usaron los valores [2, 8, 10, 20], para el *min_samples_leaf* se usaron [1, 5, 10], para la cantidad de *max_features* se usaron [None, 'log2', 'sqrt']. Para cada una de las combinaciones, se entrenó y evaluó el modelo, calculando el promedio de las exactitudes obtenidas sobre los *folds*. Como resultado de este proceso de validación cruzada, la mejor configuración encontrada fue la que utilizaba una profundidad máxima de 10, un mínimo de 8 muestras para dividir un nodo (*min_samples_split* = 8), al menos 1 muestra por hoja (*min_samples_leaf* = 1) y considerando todos los atributos disponibles al dividir (*max_features* = None).

Esta combinación obtuvo un accuracy promedio de 80.84% aproximadamente durante la validación cruzada en el conjunto de desarrollo “dev”, mostrando un buen equilibrio entre la capacidad predictiva y el control de sobreajuste mediante algunas restricciones (hiperparámetros) impuestas.

Una vez seleccionado el modelo óptimo, se procedió a entrenarlo nuevamente utilizando el conjunto de desarrollo completo, donde alcanzó un accuracy score de 84.61%

aproximadamente. Luego, el modelo fue evaluado sobre el conjunto de evaluación held-out previamente no utilizado donde alcanzó una exactitud cerca de 80.47%, un resultado coherente con lo observado durante la validación cruzada.

Finalmente, se calculó la matriz de confusión, que mostró un patrón de errores esperable a esta altura del desarrollo del trabajo.



Esta imagen representa la matriz de confusión calculada luego de evaluar el modelo final

En primer lugar, se puede ver que la mayoría de las predicciones son correctas, ya que los mayores valores (los de color más oscuro) se encuentran sobre la diagonal principal, lo que es consistente con el buen nivel de exactitud global obtenido. Se observó que ciertas clases fueron clasificadas de forma más precisa que otras, mientras que algunas se confundieron con categorías visualmente similares. En particular, son claras las confusiones frecuentes entre prendas como camisas (clase 6) y suéteres (clase 2), lo cual tiene sentido considerando la diferencia entre ambas. Por otro lado, se observa un muy buen desempeño en clases como pantalón y sandalia, donde los niveles de confusión son mínimos (los colores de toda la fila y columna correspondiente a cada clase son muy claros, salvo aquel que está en la diagonal de la matriz). Esto se explica por el hecho de que estas categorías son visualmente muy distintas del resto, lo que facilita su correcta clasificación. El análisis de la matriz de confusión complementa la métrica de exactitud, permitiendo entender mejor en qué casos específicos el modelo funciona bien y en cuáles presenta mayor dificultad.

En conclusión, el modelo de árbol de decisión ajustado mediante validación cruzada logró un buen equilibrio y demostró ser capaz de resolver bien la tarea de clasificación multiclase. Se comprobó, nuevamente, que una correcta elección de hiperparámetros, incluso en un modelo de baja complejidad como un árbol, puede conducir a un buen rendimiento en tareas multiclase. Si bien es un modelo relativamente simple, fue capaz de alcanzar una exactitud superior al 80% en el conjunto de evaluación, lo que muestra que puede captar buena parte del problema. El análisis de la matriz de confusión, además, brindó información adicional sobre las relaciones entre clases y mostró que existen ciertos



patrones de error, sobre todo entre clases que pueden presentar cierta similitud visual.

Conclusión

A lo largo del desarrollo del presente trabajo práctico, se logró explorar y analizar el conjunto de datos Fashion-MNIST desde una perspectiva integral, abarcando desde el análisis exploratorio inicial hasta la implementación y evaluación de modelos de clasificación tanto binaria como multiclase.

En primer lugar, se realizó un análisis exploratorio detallado que permitió vincular las etiquetas numéricas con las prendas correspondientes, lo cual fue fundamental para comprender el dataset y orientar los análisis posteriores. Este análisis puso en evidencia la complejidad y riqueza de la información contenida en las imágenes, destacando la importancia de realizar una visualización cuidadosa para interpretar correctamente los datos. La combinación de observación visual con análisis cuantitativo facilitó la identificación de atributos relevantes que, al ser utilizados en modelos predictivos, mejoraron notablemente su desempeño.

En la etapa de clasificación binaria, se demostró que el algoritmo de *KNN* puede alcanzar niveles de precisión muy altos incluso utilizando una cantidad muy reducida de atributos, siempre que estos sean seleccionados de manera adecuada y se combine con un ajuste correcto del parámetro *k*. Asimismo, se comprobó que el uso de atributos poco informativos afecta negativamente el rendimiento, llevándolo prácticamente al azar.

En cuanto a la clasificación multiclase, se implementaron modelos de árbol de decisión, que mostraron una buena capacidad para discriminar entre las 10 categorías presentes en el archivo. Por otra parte, la validación cruzada y la optimización de hiperparámetros resultaron fundamentales para mejorar el desempeño y controlar el sobreajuste, alcanzando más del 80% de exactitud en un conjunto de evaluación. Además, el análisis de la matriz de confusión permitió complementar esta métrica, identificando aciertos y errores frecuentes, especialmente en clases que son muy parecidas visualmente.

Finalmente, podemos decir que este trabajo afirma la relevancia del análisis exploratorio y la selección cuidadosa de atributos como pasos esenciales para el desarrollo de modelos de clasificación. Además, muestra cómo diferentes enfoques, desde métodos simples hasta modelos más complejos, pueden ser aplicados exitosamente para resolver problemas con visión y tratamiento de imágenes.